

Annotationsbasis und Evaluationsframework

Open Legal Lab 2026 · Challenge #11

eJustice.ch / Gerechter.ch · April 2026

1. Kontext und Zweck dieses Dokuments

Die Challenge #11 am Open Legal Lab 2026 hat zum Ziel, ein öffentlich zugängliches Testdatenset für die Evaluation von KI-gestützten Rechtsinformationssystemen zu entwickeln. Im Rahmen dieser Challenge stellt der Verein gerechter.ch das Tool **IUS Chat** (abrufbar unter www.iuslex.ch) zur Verfügung, ein KI-gestütztes Rechtsinformationssystem auf Basis einer Retrieval-Augmented-Generation-Architektur (RAG), das Fragen zu Schweizer Recht mit Quellenangaben beantwortet.

Dieses Dokument beschreibt die wissenschaftliche Grundlage, auf der die Annotation der Testdaten aufbaut: die sieben Evaluationsdimensionen, die Bewertungsskala, die Annotationsmethodik sowie die Qualitätssicherung.

2. Warum ein Evaluationsframework?

Der Markt der KI-gestützten Rechtsinformationssysteme wächst schneller als die Fähigkeit, ihn zu bewerten. Es fehlt eine öffentliche, regional verankerte Vergleichsgrundlage. Ein strukturiertes Evaluationsframework erfüllt hier zwei Funktionen: Erstens macht es die Qualitätsbeurteilung transparent, reproduzierbar und vergleichbar. Zweitens schafft es die Datenbasis, auf der zukünftige Forschung und die Weiterentwicklung der Tools aufbauen kann. Ohne valide Ground-Truth-Daten aus dem Schweizer Recht gibt es keine Möglichkeit, KI-Systeme für diesen spezifischen Kontext gezielt zu verbessern.

3. Struktureller Rahmen der Evaluation

Das Framework unterscheidet zwei konzeptuell verschiedene Evaluationsebenen, die unterschiedliche kognitive Anforderungen stellen und unabhängig voneinander beurteilt werden:

Retrieval-Evaluation (R1, R2): Retrieval-Evaluation (R1, R2):

Beurteilt die zurückgegebenen Quellen – sind sie relevant, und decken sie gemeinsam alle notwendigen Informationen ab? Orientiert sich an RAGAS (Shahul et al., 2023) und eRAG (Salemi & Zamani, 2024).

Generierungs-Evaluation (G1–G5): Generierungs-Evaluation (G1–G5):

Beurteilt die Antwort des Sprachmodells entlang zweier Achsen: Precision (Was die Antwort enthält, soll faktisch korrekt und quellenverankert sein) und Recall (Die Antwort soll alle rechtlich wesentlichen Aspekte vollständig abdecken). Grundlage ist das DeCE-Framework (Yu et al., 2025), ergänzt um zwei rechtsspezifische Dimensionen (G1, G2) basierend auf LegalBench (Guha et al., 2023) und LegalEval-Q (Li & Wu, 2025).

4. Die sieben Evaluationsdimensionen

Alle sieben Dimensionen werden auf einer einheitlichen dreistufigen Skala (1–3) bewertet.

#	Dimension	Definition	Skala	Literaturgrundlage
Retrieval-Seite (Quellenangaben)				
R1	Kontext-relevanz	Sind die zurückgegebenen Dokumente inhaltlich relevant für die gestellte Frage?	1–3	RAGAS (Shahul et al., 2023), ARES (Saad-Falcon et al., 2023), CCRS (Muhamed, 2025)
R2	Kontext-abdeckung	Enthalten die zurückgegebenen Dokumente gemeinsam alle Informationen, die für eine vollständige Antwort nötig wären?	1–3	RAGAS (context recall), eRAG (Salemi & Zamani, 2024), DeCE (Yu et al., 2025)
Generierungs-Seite (LLM-Antwort)				
G1	Norm-genauigkeit	Sind zitierte Artikel, Absätze, Erlasse und Gesetzesverweise korrekt referenziert und inhaltlich zutreffend?	1–3	LegalBench (Guha et al., 2023), PLawBench (Shi et al., 2026), Ryu et al. (2023)
G2	Begriffs-genauigkeit	Werden juristische Fachbegriffe mit ihrer korrekten technischen Bedeutung im Schweizer Verwaltungsrecht verwendet?	1–3	LegalEval-Q (Li & Wu, 2025), LegalBench (Guha et al., 2023)
G3	Quellen-verankerung (Faithfulness)	Ist die Antwort in den zitierten Quellen begründet, ohne Informationen zu halluzinieren oder zu erfinden?	1–3	RAGAS, ARES, RAGVUE (Murugaraj et al., 2025), Ryu et al. (2023)

#	Dimension	Definition	Skala	Literaturgrundlage
G4	Relevanz	Beantwortet die Antwort die gestellte Frage direkt und präzise?	1–3	RAGAS (answer relevance), DeCE (Yu et al., 2025), CCRS (Muhammed, 2025)
G5	Vollständigkeit	Werden alle rechtlich erheblichen Aspekte der Frage abgedeckt, die für eine fundierte Bearbeitung durch eine Verwaltungsjuristin notwendig wären?	1–3	RAGEval (Zhu et al., 2024), DeCE (Yu et al., 2025), RAGVUE (Murugaraj et al., 2025)

5. Bewertungsskala und Skalenverankerung

5.1 Dreiwertige Skala

Für alle Dimensionen wird eine dreistufige ordinale Skala (1–3) verwendet. Mangold & Hoffmann (2025) zeigen, dass menschliche Annotatorinnen bei mehrstufigen Skalen erhebliche Schwierigkeiten haben, Metrik-Definitionen konsistent anzuwenden; eine reduzierte Stufenzahl erzwingt klarere Entscheidungen und reduziert Rater-Drift. Braun (2023) belegt zudem, dass juristische Annotationsdatensätze systematisch Disagreement entfernen statt ihn zu dokumentieren – mit einer knappen, verankerten Skala wird verbleibendes Disagreement sichtbar und auswertbar.

- 1 = Nicht erfüllt: Die Dimension ist klar verletzt oder die Aussage ist nachweislich falsch.
- 2 = Teilweise erfüllt: Die Dimension ist erkennbar, aber unvollständig oder mit Mängeln.
- 3 = Vollständig erfüllt: Die Dimension ist ohne wesentliche Mängel erfüllt.

5.2 Skalenverankerung (Behaviorally Anchored Rating Scales)

Eine abstrakte Skalendefinition allein reicht nicht aus, um konsistente Annotationen zu gewährleisten. Jeder Skalenpunkt muss durch ein konkretes Beispiel aus dem Anwendungskontext verankert sein (sogenannte BARS). Nachfolgend ist das Anchoring für die Dimension G3 (Quellenverankerung / Faithfulness) als Muster ausgearbeitet. Analoge Ankerbeispiele für alle sieben Dimensionen werden zu Beginn des Hackathons in der Kalibrierungsrunde gemeinsam erarbeitet.

Beispiel: G3 – Quellenverankerung (Faithfulness)

Wert	Beschreibung	Konkretes Beispiel (IUS-Kontext)
1	Antwort enthält Aussagen, die in keinem der zitierten Dokumente belegt sind.	IUS Chat behauptet eine Beschwerdefrist von 30 Tagen; das zitierte Dokument (Art. 17 VRPG) nennt 20 Tage.
2	Antwort ist teilweise belegt, enthält aber eine oder mehrere unbelegte Ergänzungen.	Die Kernaussage zur anwendbaren Norm ist korrekt aus der Quelle entnommen, aber eine Schlussfolgerung zur Zuständigkeit wurde ohne Quellengrundlage ergänzt.
3	Jede materielle Aussage ist direkt in den zitierten Dokumenten nachweisbar.	Alle Aussagen inkl. Normen, Fristen und Zuständigkeiten sind eindeutig in den zurückgegebenen Quellen belegt und vollständig nachvollziehbar.

6. Annotationsmethodik

6.1 Drei getrennte Annotationsprojekte

Die Annotation erfolgt über die Plattform Human Signal. Das Framework unterscheidet drei konzeptuell verschiedene Annotationsaufgaben, die in getrennten Projekten bearbeitet werden. Diese Trennung ist wissenschaftlich begründet: Mangold & Hoffmann (2025) zeigen, dass kombinierte Annotationsaufgaben die Qualität aller Outputs senken, und Braun (2023) belegt, dass juristische Annotation besonders anfällig für Rater-Drift ist.

Projekt	Aufgabe	Output	Wissenschaftliche Basis
A – Retrieval	Quellen ranken und Abdeckung beurteilen	Ground Truth für R1 / R2	TREC, eRAG (Salemi & Zamani, 2024), RAGAS
B – Generation	Antwort bewerten und Referenzantwort erstellen	Rubrik-Bewertungen G1–G5 + Correction Pairs	DeCE (Yu et al., 2025), LegalBench, PLawBench
C – Paarvergleich	Zwei Modellantworten vergleichen	Preference-Daten (welche Antwort ist besser?)	Chatbot Arena (Chiang et al., 2024), InstructGPT (Ouyang et al., 2022)

6.3 Fragetypen im Testdatenset

Die Fragen im Testdatenset decken drei Kompetenzstufen ab:

- Laienfragen: Allgemeine Fragen ohne juristische Vorbildung (z.B. «Was ist Sozialhilfe?»).
- Rechtsfragen: Fokussierte Fragen zu einem bestimmten rechtlichen Aspekt (z.B. «Wann habe ich Anspruch auf Sozialhilfe?»).

- Expertenfragen: Normspezifische Fragen mit hoher Präzisionsanforderung (z.B. «Wie ist das Subsidiaritätsprinzip im Sozialhilfegesetz des Kantons Bern definiert?»).

7. Wert der Annotationsdaten und mögliche Verwendungen

Validierte Ground-Truth-Daten aus dem Schweizer Rechtskontext sind ein seltenes und wertvolles Gut. Die im Rahmen dieser Challenge entstehenden Annotationen können als Ausgangspunkt für verschiedene weiterführende Anwendungen dienen, sowohl in der Forschung als auch in der Praxis.

Beispiele:

- Retrieval-Benchmark: Die Retrieval-Annotationen aus Projekt A ermöglichen einen reproduzierbaren Benchmark (Precision@k, Recall@k, NDCG@k), mit dem verschiedene RAG-Systeme für Schweizer Recht verglichen werden können.
- Kalibrierter automatischer Richter (LLM-as-a-Judge): Die menschlichen Bewertungen aus Projekt B können genutzt werden, um automatisierte Evaluationssysteme zu kalibrieren, die neue Modellantworten ohne erneute manuelle Annotation beurteilen – skalierbar und kosteneffizient.
- Modellverbesserung (Fine-Tuning): Die Correction Pairs aus Projekt B (Originalantwort vs. Referenzantwort) bilden Rohmaterial für Verfahren der direkten Präferenzoptimierung (DPO). Für Schweizer Verwaltungsrecht und Strafrecht existiert weltweit noch kein entsprechender Datensatz.
- Benchmark für Beschaffungsentscheide: Öffentliche Stellen (Kantone, Gemeinden, Gerichte) könnten das Testdatenset nutzen, um KI-Rechtswerkzeuge bei der Beschaffung objektiv zu vergleichen.

Literaturverzeichnis

- Braun, D. (2023). I beg to differ: how disagreement is handled in the annotation of legal machine learning data sets. *Artificial Intelligence and Law*.
- Chiang, W. et al. (2024). Chatbot Arena: An Open Platform for Evaluating LLMs by Human Preference. *arXiv*.
- Enguehard, J. et al. (2025). LeMAJ (Legal LLM-as-a-Judge): Bridging Legal Reasoning and LLM Evaluation. *NLLP Workshop*.
- Guha, N. et al. (2023). LegalBench: A Collaboratively Built Benchmark for Measuring Legal Reasoning in Large Language Models. *SSRN*.
- Hashemi, H. et al. (2024). LLM-Rubric: A Multidimensional, Calibrated Approach to Automated Evaluation. *ACL*.
- Li, Y. & Wu, G. (2025). LegalEval-Q: A New Benchmark for The Quality Evaluation of LLM-Generated Legal Text. *arXiv*.
- Mangold, A. & Hoffmann, K. (2025). Human-Centered Evaluation of RAG outputs: a framework and questionnaire for human-AI collaboration. *arXiv*.
- Muhammed, A. (2025). CCRS: A Zero-Shot LLM-as-a-Judge Framework for Comprehensive RAG Evaluation. *arXiv*.
- Murugaraj, K. et al. (2025). RAGVUE: A Diagnostic View for Explainable and Automated Evaluation of Retrieval-Augmented Generation. *arXiv*.
- Ouyang, L. et al. (2022). Training language models to follow instructions with human feedback (InstructGPT). *NeurIPS*.
- Rafailov, R. et al. (2023). Direct Preference Optimization: Your Language Model is Secretly a Reward Model. *NeurIPS*.
- Ryu, C. et al. (2023). Retrieval-based Evaluation for LLMs: A Case Study in Korean Legal QA. *NLLP*.
- Saad-Falcon, J. et al. (2023). ARES: An Automated Evaluation Framework for Retrieval-Augmented Generation Systems. *NAACL*.
- Salemi, A. & Zamani, H. (2024). Evaluating Retrieval Quality in Retrieval-Augmented Generation. *SIGIR*.
- Shahul, E. et al. (2023). RAGAs: Automated Evaluation of Retrieval Augmented Generation. *EACL*.
- Shi, Y. et al. (2026). PLawBench: A Rubric-Based Benchmark for Evaluating LLMs in Real-World Legal Practice. *arXiv*.
- Thakur, N. et al. (2021). BEIR: A Heterogeneous Benchmark for Zero-shot Evaluation of Information Retrieval Models. *NeurIPS*.
- Yu, F. et al. (2025). Beyond Pointwise Scores: Decomposed Criteria-Based Evaluation of LLM Responses (DeCE). *EMNLP*.
- Zhu, K. et al. (2024). RAGEval: Scenario Specific RAG Evaluation Dataset Generation Framework. *ACL*.